

摘要

随着大语言模型和智能体技术的发展，多智能体协同对话系统逐渐被应用于复杂问答、任务规划、知识服务和交互式推荐等场景。为了支持长期交互和跨轮协作，许多系统引入共享记忆机制，将历史对话、检索结果和智能体生成内容写入外部记忆库。然而，共享记忆在提升系统连续性的同时，也带来了新的可靠性风险：错误前提、无证据推断或幻觉内容一旦被写入共享记忆，可能在后续多轮对话中被其他智能体反复检索、引用和派生，最终形成持续性的记忆污染。

针对上述问题，本文围绕多智能体共享记忆系统中的记忆幻觉传播识别与知识编辑展开研究。首先，本文提出一种面向共享记忆的幻觉传播图构建方法，将对话轮次、问题、回答、原子事实、共享记忆、可信知识库条目和知识编辑动作建模为异构图节点，将检索、使用、支持、反驳、派生、写入、废弃和修复等关系建模为图边，从而记录错误记忆从产生、写入、检索、复用到修复的全过程。其次，本文提出 MKE-MAS (Memory Knowledge Editing for Multi-Agent Systems) 共享记忆知识编辑机制，对多轮对话中新产生的候选事实进行 claim 级抽取、实体链接、证据检索、事实验证和编辑决策，以阻止错误记忆进入长期共享知识，并将正确、可验证的对话记忆提升为长期知识。

实验部分基于青铜器结构化知识库构造多类攻击性测试集，包括 LFQA、NOE、FPI、MIS、REP、REV 以及单长对话幻觉传播测试。实验结果表明，结构化知识编辑接入在错误前提诱导和无依据问题测试中能够提高系统的纠错与拒答能力，在重复强化诱导测试中也表现出一定的错误抵抗能力。长对话案例进一步表明，本文构建的传播图能够较清晰地记录错误记忆从产生、写入、复用到部分修复的过程。与此同时，实验也显示，相似实体混淆、知识编辑结果接入策略和污染记忆长期过滤仍是后续需要进一步改进的问题。关键词：多智能体系统；共享记忆；记忆幻觉；知识编辑；传播图；FAISS

Abstract

With the development of large language models and autonomous agents, multi-agent dialogue systems have been increasingly applied to complex question answering, task planning, knowledge services, and interactive reasoning. To support long-term interaction and cross-turn collaboration, many systems introduce shared memory mechanisms that store dialogue history, retrieved evidence, and agent-generated content in external memory. Although shared memory improves continuity, it also introduces new reliability risks. Once false premises, unsupported inferences, or hallucinated facts are written into shared memory, they may be repeatedly retrieved, reused, and propagated by other agents in later conversations, resulting in persistent memory contamination.

To address this problem, this thesis studies hallucination propagation tracing and knowledge editing in shared-memory multi-agent systems. First, this thesis proposes a memory hallucination propagation graph, where dialogue turns, questions, answers, atomic claims, shared memories, trusted knowledge-base entries, and edit actions are represented as heterogeneous nodes, while retrieval, usage, support, contradiction, derivation, insertion, deprecation, and repair relations are represented as graph edges. Second, this thesis proposes MKE-MAS, a memory-based knowledge editing mechanism for multi-agent systems. MKE-MAS performs claim extraction, entity linking, evidence retrieval, factual verification, and editing decisions on candidate facts generated during multi-turn conversations, thereby preventing false memories from entering long-term shared knowledge and promoting verified dialogue memories into reusable knowledge.

Experiments are conducted on a structured bronze artifact knowledge base. Multiple adversarial test sets are constructed, including LFQA, NOE, FPI, MIS, REP, REV, and a single long-dialogue hallucination propagation case. The experimental results show that structured access to edited knowledge improves false-premise correction and no-evidence rejection in several settings, and provides certain resistance to repeated false claims. The long-dialogue case further demonstrates that the proposed propagation graph can explicitly record how a false memory is introduced, stored, reused, and partially repaired. The results also indicate that similar-entity confusion, edited-knowledge routing, and long-term contaminated-memory filtering remain important challenges for future improvement. Keywords: Multi-Agent Systems; Shared Memory; Memory Hallucination; Knowledge Editing; Propagation Graph; FAISS

缩略词表

英文缩写	英文全称	中文含义
LLM	Large Language Model	大语言模型
MAS	Multi-Agent System	多智能体系统
MKE-MAS	Memory Knowledge Editing for Multi-Agent Systems	面向多智能体系统的记忆知识编辑
FAISS	Facebook AI Similarity Search	向量相似度检索库
RAG	Retrieval-Augmented Generation	检索增强生成
LFQA	Long-Form Question Answering	长文本问答
NOE	No-Evidence Question	无依据问题测试
FPI	False Premise Induction	错误前提诱导
MIS	Similar Entity Confusion	相似实体混淆
REP	Repetition Reinforcement Induction	重复强化诱导
REV	Correction Repair Test	纠错修复测试
KB	Knowledge Base	知识库
NLI	Natural Language Inference	自然语言推理

目录

1. 绪论
- 1.1 研究背景

1.2 共享记忆幻觉传播问题

1.3 研究目标及内容

1.4 本文组织结构
2. 相关技术介绍
- 2.1 大语言模型智能体与长期记忆

2.2 多智能体共享记忆机制

2.3 知识编辑技术

2.4 幻觉检测与事实验证

2.5 图结构溯源与错误传播分析

2.6 本章小结

3. 面向共享记忆的幻觉传播图构建方法

3.1 引言

3.2 问题定义

3.3 图节点与图边设计

3.4 对话日志与依赖关系采集

3.5 传播路径识别方法

3.6 传播图指标

3.7 本章小结

4. 面向多智能体系统的共享记忆知识编辑方法

4.1 引言

4.2 系统总体流程

4.3 Claim 抽取与实体链接

4.4 证据检索与事实验证

4.5 知识编辑决策机制

4.6 污染记忆修复机制

4.7 本章小结

5. 实验设计与结果分析

5.1 实验环境

5.2 数据集与测试集构造

5.3 评价指标

5.4 对比实验

5.5 知识编辑接入策略消融实验 5.6 长对话传播案例分析 5.7 实验结果总评 5.8 本章小结

6. 总结与展望

6.1 结论

6.2 不足与改进

6.3 未来工作展望

参考文献

作者简介

附录 A 系统实现细节

附录 B 测试样例

附录 C 人工智能工具使用记录

1 绪论

1.1 研究背景

大语言模型在自然语言理解、知识问答、复杂推理和工具调用等任务中表现出较强能力。在此基础上，智能体系统通过为大语言模型配置工具、记忆、规划和反思等能力，使其能够在多轮交互中完成更复杂的任务。与单一智能体对话系统相比，多智能体系统通过角色分工和协作机制，将复杂任务拆解为检索、回答、验证、反思和记忆管理等多个子过程，从而提升系统的模块化程度和任务处理能力。

在知识服务场景中，多智能体系统通常需要处理长轮次交互、跨轮追问、多实体比较和动态知识更新等问题。单纯依赖上下文窗口存在问题，在长期对话后会因为过长的窗口而降低生成回答的效率，因此系统往往需要引入外部记忆机制，将历史对话、检索结果和智能体生成内容保存到共享记忆库中，并在后续问题中重新检索使


用。共享记忆机制能够增强系统的连续性，使不同智能体共享对话历史和中间结果，从而支持长期协作和个性化问答。

然而，共享记忆机制也引入了新的可靠性风险。与单轮回答中的幻觉不同，共享记忆中的错误信息具有持久性和传播性：单一智能体并不会自然具备分辨记忆库中信息真伪的能力，一旦幻觉或其它具有事实错误的内容被某个智能体错误地写入共享记忆，它可能在后续对话中被其他智能体检索、引用、改写和派生，导致越来越多的幻觉进入共享记忆库，进而影响多个回答和新的记忆条目。这种情况被称为多智能体的记忆幻觉。简而言之，普通幻觉主要影响当前回答，而记忆幻觉会改变系统后续可检索的外部状态。

因此，如何在共享记忆库中识别幻觉，如何追踪错误记忆影响智能体系统生成后续回答的详细过程，以及如何通过知识编辑预防污染产生、阻止污染扩散，成为多智能体系统可靠性研究中的重要问题。

已有研究较多关注单一智能体或单轮生成中的幻觉检测问题，而多智能体系统中的共享记忆会使错误信息跨轮次、跨智能体传播。因此，在将单智能体幻觉检测方法迁移到多智能体系统之外，还需要进一步分析错误信息如何进入共享记忆、如何被后续智能体调用，以及知识编辑方法在修复错误记忆过程中表现出的不同点。

图 1.1 共享记忆幻觉传播问题示意图



1.2 共享记忆幻觉传播问题

本文关注的核心问题是多智能体共享记忆系统中的记忆幻觉传播。所谓记忆幻觉，是指系统将错误事实、无依据推断、实体错配信息或不可靠用户输入写入共享记忆，并在后续交互中将其作为可复用上下文或知识使用。记忆幻觉在引入长期记忆的单一智能体或使用外部共享记忆的多智能体系统中都会出现，在多智能体场景中尤为突出，具有以下特点：

- 持久性**：错误信息会被保存到外部记忆中，不会随着单轮对话结束而消失。
- 传染性**：错误记忆可能成为其它智能体生成新回答或新记忆的依据，形成二次污染。
- 隐蔽性**：用户往往只能看到最终回答，难以判断错误来自模型生成、检索结果还是共享记忆。记忆幻觉的传播分为四个阶段：产生阶段，用户错误前提或 Agent 无依据生成；写入阶段，错误 claim 被保存为候选记忆或共享记忆；复用阶段，后续 Agent 检索并使用该记忆；派生阶段，错误记忆进一步生成新回答或新记忆。本文以青铜器相关知识问答作为实验场景，基于结构化青铜器知识库构造多类多轮对话测试，用于观察共享记忆幻觉的产生、传播与修复过程。在该场景中，记忆幻觉可能表现为多种形式。例如，系统可能把 A 器物的出土地点错误绑定到 B 器物上；可能把用户以传闻方式提供的错误年代写入共享记忆；也可能在多轮重复诱导下提高错误 claim 的可信度。若这些错误没有被及时识别和修复，系统后续回答将持续受到影响。本文在提升回答准确率的基础上，重点分析错误信息进入记忆后如何被调用、如何影响后续回答的全过程，并对其进行治理。

1.3 研究目标及内容

本文的研究目标是将单智能体幻觉治理的两种重要方法引入多智能体协作的场景，尝试构建一种面向多智能体系统的共享记忆幻觉传播识别与知识编辑方法，使系统能够在多轮对话中记录记忆来源、识别污染记忆、追踪传播路径，并将正确对话记忆沉淀为长期知识。

具体来说，本文主要研究内容包括以下两个方面：

(1) 一种面向多智能体共享记忆的幻觉传播图构建方法

该方法将多轮对话过程中的问题、回答、原子事实、共享记忆、可信知识库条目和知识编辑动作统一建模为异构图节点，将检索、使用、支持、反驳、派生、写入、废弃和修复等关系建模为图边。通过建立该幻觉传播图，系统可以将污染在共享记忆库中传播的过程可视化，相对直观地追踪污染的来源和流向，并计算传播深度和广度等指标。

(2) 一种面向多智能体共享记忆的知识编辑方法

该方法从多轮对话生成的结果中抽取候选事实，对每条 claim 进行实体链接、证据检索和事实验证，并根据验证结果执行插入、合并、拒绝、废弃或修复等编辑动作。通过该机制，系统可以对原始的知识库进行二次加工和“再发现”，将正确、可验证的对话内容提升为可复用知识，同时确保存在问题的条目不会在此过程中被引入知识库。

本文采用根据中国大百科全书网页版“著名青铜器”页面自建的结构化知识库作为实验事实来源，构建 LFQA、NOE、FPI、MIS、REP、REV 以及单长对话幻觉传播测试集，从回答正确性、记忆污染治理和传播路径分析等多个角度验证所提出方法的有效性。

1.4 本文组织结构

第一章为绪论，介绍多智能体共享记忆系统的研究背景，分析共享记忆幻觉传播问题，并给出本文的研究目标和主要内容。

第二章为相关技术介绍，梳理大语言模型智能体与长期记忆、多智能体共享记忆机制、知识编辑与外部记忆编辑、幻觉检测与事实验证以及图结构溯源与错误传播分析等相关研究。

第三章提出面向共享记忆的幻觉传播图构建方法，介绍问题定义、图节点与图边设计、对话日志与依赖关系采集方法、传播路径识别算法以及图分析指标。

第四章提出面向多智能体系统的共享记忆知识编辑方法，介绍系统总体流程、claim 抽取与实体链接、证据检索与事实验证、知识编辑决策机制以及污染记忆修复机制。

第五章进行实验设计与结果分析，介绍实验环境、数据集与测试集构造、评价指标、对比实验、消融实验和长对话传播案例分析。

第六章总结全文工作，分析本文方法的不足，并展望未来研究方向。

图 1.2 本文组织结构图



2 相关技术介绍

本章围绕本文研究所涉及的关键技术和相关工作展开介绍。本文的核心问题是多智能体共享记忆系统中的记忆幻觉传播识别与知识编辑，因此相关研究主要包括五个方面：大语言模型智能体与长期记忆、多智能体共享记忆机制、知识编辑与外部记忆编辑、幻觉检测与事实验证，以及图结构溯源与错误传播分析。通过对这些方向

的梳理，可以看出现有研究虽然分别解决了智能体记忆、协作、事实验证和知识更新等问题，但仍缺少一种面向共享记忆污染传播的统一追踪与修复机制。

2.1 大语言模型智能体与长期记忆

大语言模型在自然语言理解、文本生成和复杂推理任务中表现出较强能力。在此基础上，ReAct 提出让大语言模型交替生成 reasoning trace 和 action，通过“思考—行动—观察”的循环完成任务[1]。研究者在大语言模型基础上加入外部工具调用、任务规划、外部记忆和自我反思等能力，将大语言模型扩展为智能体系统，使其能够完成更复杂的任务[2]。与传统问答模型相比，智能体不再完全依赖模型参数，外部工具和外部知识源的加入使其能够在多轮交互中完成相比传统对话模型更复杂的任务。Generative Agents: Interactive Simulacra of Human Behavior[3]提出了经典的 Agent 长期记忆架构，agent 会使用自然语言格式保存记忆，并根据相关性和就近原则在生成新内容有需要时进行检索。长期记忆机制是智能体系统的重要组成部分，它能够保存历史对话、用户偏好、中间推理结果和已验证知识等内容，从而突破前文提到的上下文窗口限制。

MemGPT 用操作系统的内存调度类比长期记忆和上下文窗口的关系，并提出用显式调度的方法管理智能体的记忆和上下文[4]。现有智能体记忆方法通常关注记忆的存储、检索、更新和遗忘，例如通过向量数据库保存自然语言记忆，通过摘要机制压缩历史对话，或通过反思机制提炼高层经验[5]。这些方法有助于提高系统连续性，但在许多场景中仍缺少对记忆真实性的严格验证。若系统直接将未经审核的对话内容写入长期记忆，其中包含的错误信息可能被持久保存并影响后续回答的准确性。

然而，现有智能体记忆研究较少关注记忆内容本身是否可靠。在实际系统中，如果智能体将错误回答、无依据推断或用户错误前提写入长期记忆，这些信息可能在后续对话中被再次检索和使用。因此，长期记忆不仅是能力增强模块，也可能成为错误信息持久化的载体。

本文在上述工作的基础上，进一步关注长期记忆的可信管理问题。本文将共享记忆中的每条记忆视为具有来源、置信度、验证状态和污染状态的系统对象，并在后续章节中通过传播图和知识编辑机制对其进行追踪、过滤和修复。

2.2 多智能体共享记忆机制

AutoGen 提出通过多个可对话智能体进行协作，支持人类、工具和多个模型之间的交互[6]，这是多智能体系统最具代表性的框架，本文实验中使用的多智能体对话系统就基于这一框架。Camel 提出多智能体系统的角色分工机制[7]，通过角色扮演方式构建交互逻辑，让扮演不同角色的智能体围绕任务进行协作。多智能体系统通过将复杂任务分配给多个具有不同职责的智能体，提升了系统处理复杂问题的能力。典型多智能体系统通常包含规划者、检索者、回答者、验证者、执行者和反思者等角色。共享记忆机制使不同智能体能够访问同一记忆池，从而复用历史信息和中间结果，提高系统协作效率[8]。例如，检索智能体可以将相关知识写入共享记忆，回答智能体可以调用这些记忆生成回答，验证智能体可以对回答中的关键事实进行检查，记忆管理智能体则可以对历史信息进行总结和更新。相比每个智能体各自维护私有上下文，共享记忆有助于保持系统整体状态一致。

但是，共享记忆也会放大错误信息的影响范围。在单一智能体系统中，错误通常局限于当前模型实例或当前对话上下文；而在多智能体系统中，一条错误记忆一旦进入共享记忆库，就可能被多个智能体检索、引用和派生，进而影响整个系统的信息环境。因此，共享记忆中的错误具有跨轮次、跨智能体和跨任务传播的风险。

现有多智能体研究更多关注协作效率、角色分工和任务完成能力，而对共享记忆中的错误来源、调用路径和修复过程关注不足。本文将共享记忆视为一种需要被验证和编辑的系统状态，进一步研究错误记忆如何在多智能体系统中传播，以及系统如何通过知识编辑机制阻止和修复这种传播。

2.3 知识编辑与外部记忆编辑

知识编辑最初主要关注模型参数中的事实知识修改，ROME 通过因果追踪定位模型中存储事实知识的关键层，并提出 Rank-One Model Editing 修改模型内部事实关联[9]。知识编辑旨在修改模型或系统中的知识，使系统在后续任务中使用更新后的事实[10]中基于ROME提出了批量知识编辑的方法，用于处理多轮对话产生的大量素材。现有知识编辑方法大致可以分为参数编辑和外部记忆编辑两类。参数编辑方法直接修改大语言模型内部参数，能够改变模型对特定事实的回答；外部记忆编辑方法则不修改模型参数，而是将编辑后的知识存入外部记忆，并在推理时通过检索或上下文注入影响模型回答[12]。对于多智能体系统而言，外部记忆编辑更适合当前研究场景。一方面，实际系统可能调用闭源或远程 API 模型，无法访问模型参数；另一方面，本文关注的错误主要发生在共享记忆层，而不是模型参数层。SERAC[11]将编辑内容保存到显式memory中，推理时检索相关编辑知识来调整回答；IKE 研究通过上下文示例完成事实编辑；GRACE 和 WISE 则关注长期持续编辑和编辑知识路由问题。这些基于单一智能体的方法为本文将知识编辑结果存储在外部的 edited KB 或共享记忆中提供了参考。本文在以上方法思想和技术的基础上，将方法扩展到多智能体系统，采用外部记忆式知识编辑方法，将对话中新产生的候选事实经过验证后写入长期知识，并对错误记忆执行拒绝、隔离、废弃操作。外部记忆式知识编辑技术还有一项重要问题，如何处理原始的零阶知识和编辑产生的一阶知识的关系。WISE对于这个问题提出主记忆与侧记忆的设计，通过路由机制决定应该优先调用哪一部分知识，这是一个该问题的通用解法[13]。

2.4 幻觉检测与事实验证

大语言模型在开放式问答、长文本生成和多轮对话任务中可能产生与事实不一致的内容。模型可能在缺乏证据的情况下生成看似合理但实际错误的信息，也可能在用户问题包含错误前提时顺着错误假设继续回答。这类现象通常被称为幻觉。对于普通单轮问答系统而言，幻觉主要表现为最终回答中的事实错误；而在引入长期记忆和共享记忆机制的多智能体系统中，幻觉还可能进一步被保存、复用和传播。因此，幻觉检测与事实验证不仅是评价回答质量的重要方法，也是本文后续进行共享记忆知识编辑的基础。

事实验证研究通常将模型生成内容拆解为 claim，并判断 claim 是否被证据支持。FEVER 将事实核查任务形式化为对给定 claim 进行证据检索，并判断该 claim 是否被证据支持、反驳或无法判断。Thorne 等人提出的 FEVER 数据集将事实核查任务形式化为对给定 claim 进行证据检索，并判断该 claim 是否被证据支持、反驳或无法判断[14]。该任务定义为本文的事实验证模块提供了重要参考：在本文中，VerifierAgent 对每条候选 claim 输出 supported、contradicted、unsupported、ambiguous 或 partially_supported 等标签，本质上就是对 FEVER 式事实验证任务在多智能体共享记忆场景下的扩展。

对于长文本回答，仅判断整段回答是否正确往往是不充分的。一个回答可能同时包含多个事实，其中一部分被知识库支持，另一部分可能与知识库冲突，或者知识库中没有记载。Min 等人提出的 FActScore 将长文本生成结果拆分为若干 atomic facts，并逐条评估每个原子事实是否被可靠来源支持[15]。这一思想对本文具有直接启发意义。由于多智能体系统的回答通常包含时代、器类、出土地点、馆藏、尺寸、铭文等多个属性，如果直接验证整段回答，系统难以定位具体错误来源，也难以决定应该修复哪一条记忆。因此，本文采用 claim 级事实验证方法，先从回答中抽取原子事实，再分别进行实体链接、证据检索和验证判断。

除事实验证外，幻觉评估研究还关注如何系统性构造和识别模型幻觉。HaluEval 构建了大规模幻觉评估基准，覆盖问答、摘要和对话等任务，用于评估大语言模型在不同生成场景下产生幻觉的倾向[16]。本文在实验设计中借鉴了这种测试集构造思想，围绕青铜器知识库构建了无依据问题测试、错误前提诱导、相似实体混淆、重复强化诱导和纠错修复测试。这些测试并非只考察最终回答是否正确，而是进一步观察错误信息是否被写入共享记忆，以及是否在后续多轮交互中被再次召回和使用。此外，SelfCheckGPT 和 RAGAS 分别从生成结果自检一致性与检索增强生成评估角度为幻觉检测提供了补充参考[24][25]。

综合来看，现有幻觉检测和事实验证方法为本文提供了 claim 抽取、证据检索和支持关系判断的基础。与已有研究不同，本文的关注点进一步从“回答中是否存在幻觉”扩展到“幻觉是否进入共享记忆并发生传播”。因此，本文不仅记录每条 claim 的验证结果，还将其与对话轮次、智能体回答、共享记忆和知识编辑动作相连接，为后续构建记忆幻觉传播图和执行知识编辑提供依据。

2.5 图结构溯源与错误传播分析

在复杂系统中，错误往往不是孤立产生的，而是沿着信息依赖关系逐步传播。数据溯源研究关注结果数据的来源及其生成过程，强调通过记录输入、中间步骤和输出之间的依赖关系来解释系统行为[17]。类似地，在多智能体共享记忆系统中，最终回答可能受到用户问题、检索结果、历史记忆、智能体生成内容和知识编辑动作的共同影响，因此也需要一种结构化方法记录这些依赖关系。

图结构是表示复杂依赖关系的常用工具。通过将对象表示为节点、将对象之间的关系表示为边，图结构可以清晰表达信息来源、传递路径和影响范围。在本文场景中，问题、回答、claim、memory、knowledge、KBItem 和 edit action 可以被建模为异构图节点，检索、使用、支持、反驳、写入、废弃和修复等关系可以被建模为图边。通过这种建模方式，系统能够从错误回答反向追踪污染源，也能够从污染记忆正向分析其影响范围。[18] 近期多智能体时序图安全研究也表明，将跨轮交互转化为可分析图结构有助于长上下文场景下的风险定位 [26]。

需要指出的是，本文构建的记忆幻觉传播图并不试图还原大语言模型内部真实推理过程。由于模型内部推理机制难以被直接可靠观测，本文只记录系统外部可观测的依赖关系，包括记忆是否被检索、是否被智能体声明使用、claim 是否被知识库支持或反驳、记忆是否被知识编辑器废弃或修复等。这种外部可观测传播图虽然不能完全等价于模型内部因果机制，但能够为系统调试、错误定位和记忆修复提供可操作依据。

现有图追踪和溯源方法多用于数据处理流程、科学工作流或任务失败分析，而本文将该思想应用于多智能体共享记忆污染问题。本文关注的不只是任务是否失败，而是错误记忆如何从用户输入或智能体回答进入共享记忆，又如何后续对话中被检索、使用、派生和修复。第三章将在此基础上进一步定义记忆幻觉传播图的节点、边和路径分析方法。

2.6 本章小结

本章介绍了本文研究所需的相关技术和研究基础。大语言模型智能体与长期记忆研究说明，外部记忆能够增强智能体的长期交互能力；多智能体共享记忆机制说明，共享记忆能够提高多个智能体之间的信息复用效率；知识编辑研究为修改和维护系统知识提供了方法基础；幻觉检测与事实验证研究为 claim 级验证和证据判断提供了技术依据；图结构溯源研究则为错误来源追踪和传播路径分析提供了建模工具。

然而，现有研究仍存在不足。智能体记忆研究主要关注记忆如何提升连续性，而较少关注记忆真实性；多智能体研究主要关注协作效率，而较少关注共享记忆污染；知识编辑研究多面向模型参数或单模型外部记忆，而较少关注多智能体共享记忆层面的编辑；幻觉检测研究多关注最终回答，而较少分析错误 claim 是否进入记忆并继续传播；图溯源研究虽然能够记录依赖关系，但尚未与共享记忆知识编辑形成闭环。

因此，本文后续将围绕两个问题展开：第一，如何构建面向共享记忆的幻觉传播图，以记录错误记忆的来源、传播路径和影响范围；第二，如何设计面向多智能体系统的共享记忆知识编辑机制，以阻止、隔离和修复污染记忆。第三章将首先介绍记忆幻觉传播图的构建方法。

2.6 本章小结

本章介绍了本文研究所需的相关技术基础。首先，智能体长期记忆机制为多轮交互提供了持续状态，但也带来了记忆真实性问题。其次，多智能体共享记忆能够提高协作效率，但错误信息可能在多个智能体之间传播。再次，知识编辑为修正错误知识提供了方法基础，但现有研究较少关注共享记忆层面的污染治理。最后，幻觉检测和图结构溯源为本文的 claim 级验证和传播路径分析提供了技术支持。


综上，现有研究虽然分别关注了智能体记忆、知识编辑、幻觉检测和错误追踪，但仍缺少一种面向多智能体共享记忆的完整机制，能够同时记录错误记忆的来源、传播路径、影响范围和修复过程。本文后续章节将围绕这一问题展开方法设计。


3 面向共享记忆的幻觉传播图构建方法


3.1 引言

本章旨在解决多智能体共享记忆系统中错误记忆“从哪里来、如何传播、影响了什么”的问题。传统幻觉检测方法通常只判断最终回答是否正确，而难以揭示错误信息在系统内部的流动过程。对于引入共享记忆的多智能体系统而言，仅检测最终回答是不够的，因为错误信息可能已经进入记忆库，并在未来对话中继续被调用。此时，错误不再是单轮输出问题，而是系统状态污染问题[17][19]。近年来也有研究将多智能体交互过程建模为信息依赖图或时序图，用于追踪任务失败的详细原因[26]。受此启发，本文提出一种基于信息依赖图思想的，面向共享记忆的幻觉传播图构建方法，用于记录多智能体系统中记忆的产生、检索、使用、派生和修复过程。该方法通过记录对话、检索、回答、claim 抽取、证据验证和知识编辑过程中的关键节点与关系，构建可追踪的异构图。该图既可以用于定位污染记忆的来源，也可以用于分析污染记忆的传播范围和修复效果。必须澄清，本文传播图记录的是外部可观测依赖关系，包括检索日志、显式使用记录、claim 验证结果和知识编辑日志，而不是对大语言模型内部真实推理过程的直接还原[20]。

图 3.1 记忆幻觉传播图构建流程







3.2 问题定义

设多智能体系统在一个 episode 中产生多轮对话：

$$D = \{T_1, T_2, \dots, T_n\}$$

其中每一轮对话 T_i 包含用户问题 Q_i 、系统回答 A_i 、检索到的记忆集合 R_i 、实际使用的记忆集合 U_i 以及从回答中抽取出的候选事实集合 C_i 。

共享记忆库记为：

$$M = \{m_1, m_2, \dots, m_k\}$$

其中每条记忆 m_j 包含内容、来源、置信度、状态和污染标记等属性。可信知识库记为 K ，用于验证候选事实是否被支持。

若某条记忆 m_j 的内容与可信知识库 K 中的证据相矛盾，或其来源为无证据用户输入、错误前提或被反驳的智能体回答，则称该记忆为污染记忆，记为：

$$m_j.status = contaminated$$

本文的目标是构建一个传播图：

$$G = (V, E)$$

本文借鉴 provenance 模型中 Entity、Activity 和 Agent 的抽象[27][28]，将多轮对话中的各要素表示为异构图节点和图边。其中 V 表示节点集合，包括对话轮次、问题、回答、claim、memory、knowledge 和 KBItem； E 表示边集合，包括 contains、retrieves、uses、extracts、supports、contradicts、promoted_to、deprecated_by、repairs 和 contaminates 等关系。对于 claim 节点，本文进一步借鉴 FEVER 的 claim-evidence 事实验证框架[14]和 FActScore 的 atomic facts 拆解思想[15]。

传播路径是指从错误 claim 或污染 memory 出发，沿图中 promoted_to、retrieves、uses、derived_from、contaminates 等边到达后续 answer、claim 或 memory 的路径。传播路径用于描述错误信息如何从源头扩散到后续系统输出。

3.3 图节点与图边设计

本文将传播图设计为异构图。节点类型包括：

节点类型	含义	示例
Turn	对话轮次	T_0001
Question	用户或测试智能体问题	Q_0001

节点类型	含义	示例
Answer	系统回答	A_0001
Claim	从回答中抽取的原子事实	C_0001
Memory	共享记忆条目	M_0001
Knowledge	知识编辑后生成的长期知识	K_0001
KBItem	原始可信知识库条目	KB_363144
EditAction	知识编辑动作	E_0001
Agent	智能体	AnswerAgent

图边类型包括：


边类型	含义
contains	对话轮次包含问题或回答
asks	智能体提出问题
answers	智能体生成回答
retrieves	智能体检索到某条记忆
uses	智能体显式使用某条记忆
extracts	从回答中抽取 claim
supports	证据支持 claim
contradicts	证据反驳 claim
derived_from	新记忆由旧记忆派生
promoted_to	claim 被提升为长期知识
rejected_by	claim 被知识编辑器拒绝
deprecated_by	旧记忆被新知识废弃
repairs	修复知识修复污染记忆
contaminates	污染记忆影响后续回答或记忆

边方向说明：

边	方向	含义
Answer -> Claim	extracts	回答中抽取出 claim
Memory -> Answer	used_in	某条记忆被用于生成回答
KBItem -> Claim	supports / contradicts	知识库证据支持或反驳 claim
Claim -> Memory	promoted_to	claim 被写入记忆

边	方向	含义
Correction -> Memory	repairs	修复知识修复污染记忆

图 3.2 图节点与图边类型示意图



3.4 对话日志与依赖关系采集

传播图的构建依赖系统运行过程中的日志采集。本文将每轮对话记录为结构化日志，包括 episode_id、turn_id、输入问题、系统回答、检索到的记忆、实际使用的记忆和生成的 claim。其中检索记录部分借鉴了 RAG 与稠密检索问答中对检索证据和生成结果关系的显式记录思路[21][22]。对话日志表可设计如下：

```
CREATE TABLE dialogue_log (
    turn_id TEXT PRIMARY KEY,
    episode_id TEXT,
    test_category TEXT,
    turn_index INTEGER,
    speaker TEXT,
    input_text TEXT,
    output_text TEXT,
    retrieved_memory_ids TEXT,
    used_memory_ids TEXT,
    generated_claim_ids TEXT,
    timestamp DATETIME
);
```

检索日志用于记录 FAISS 返回的记忆：

```
CREATE TABLE retrieval_log (  
  log_id TEXT PRIMARY KEY,  
  turn_id TEXT,  
  agent_id TEXT,  
  query TEXT,  
  retrieved_memory_id TEXT,  
  rank INTEGER,  
  score REAL,  
  timestamp DATETIME  
);
```

使用日志用于记录智能体实际声明使用的记忆：

```
CREATE TABLE usage_log (  
  log_id TEXT PRIMARY KEY,  
  turn_id TEXT,  
  agent_id TEXT,  
  answer_id TEXT,  
  used_memory_id TEXT,  
  usage_type TEXT,  
  timestamp DATETIME  
);
```

传播图的核心图边表设计如下：

```
CREATE TABLE graph_edges (  
  edge_id TEXT PRIMARY KEY,  
  source_node TEXT NOT NULL,  
  target_node TEXT NOT NULL,  
  edge_type TEXT NOT NULL,  
  confidence REAL,  
  created_turn TEXT,  
  created_by TEXT,  
  metadata TEXT,  
  timestamp DATETIME  
);
```

图边由日志信息转化而来：

日志来源	生成的图边	含义
dialogue_log	Turn contains Question / Answer	对话轮次包含输入和输出
retrieval_log	Agent retrieves Memory	某 Agent 检索到某条记忆

日志来源	生成的图边	含义
usage_log	Agent uses Memory / Memory used_in Answer	某条记忆被实际使用
claim 表	Answer extracts Claim	从回答中抽取 claim
evidence 表	KBItem supports / contradicts Claim	证据支持或反驳 claim
edit_log	Claim rejected_by EditAction / Memory deprecated_by Knowledge	编辑动作更新记忆状态

本节需要特别区分三种关系：retrieved 表示某条记忆被检索到但不一定被使用；used 表示某条记忆被智能体声明用于回答；supports / contradicts 表示某条证据在语义上支持或反驳某个 claim。这一区分有助于判断污染记忆究竟是被系统召回了但未使用，还是被实际用于生成错误回答。

3.5 传播路径识别方法

在得到传播图后，本文通过图遍历识别污染记忆的来源和影响范围。

3.5.1 污染源反向追踪

对于一个错误回答或污染记忆节点，系统沿图中的 extracts、used_in、derived_from、promoted_to 等边反向查找其来源。目标是确定错误信息最初来自用户错误前提、智能体生成幻觉、实体错配还是无依据推断。

```
def trace_back_source(graph, node_id):
    visited = set()
    queue = [node_id]
    source_paths = []

    while queue:
        node = queue.pop(0)
        if node in visited:
            continue
        visited.add(node)

        for pre in graph.predecessors(node):
            edge_type = graph.get_edge_data(pre, node)["edge_type"]
            if edge_type in ["extracts", "used_in", "derived_from", "promoted_to",
"contains"]:
                source_paths.append((pre, edge_type, node))
                queue.append(pre)

    return source_paths
```

3.5.2 污染影响正向追踪

对于一个污染记忆节点，系统沿 retrieves、uses、derived_from、contaminates 等边正向遍历，查找它影响了哪些回答、claim 和新记忆。


```
def trace_forward_impact(graph, memory_id):
    visited = set()
    queue = [memory_id]
    impacted_nodes = []

    while queue:
        node = queue.pop(0)
        if node in visited:
            continue
        visited.add(node)

        for nxt in graph.successors(node):
            edge_type = graph.get_edge_data(node, nxt)["edge_type"]
            if edge_type in ["used_in", "derived_from", "contaminates",
                            "supports"]:
                impacted_nodes.append((node, edge_type, nxt))
                queue.append(nxt)

    return impacted_nodes
```

3.6 传播图指标

本文使用以下指标评估记忆幻觉传播情况：传播深度和传播广度的定义借鉴复杂网络中路径长度与影响范围的刻画思路[23]。污染写入率 $\text{Memory Pollution Rate} = \frac{\text{被写入共享记忆的错误 claim 数}}{\text{所有错误诱导 claim 数}}$ 污染召回率 $\text{Contaminated Recall Rate} = \frac{\text{后续检索中召回污染记忆的次数}}{\text{总检索次数}}$ 污染使用率 $\text{Contaminated Usage Rate} = \frac{\text{被智能体使用的污染记忆次数}}{\text{被检索到的污染记忆次数}}$ 传播深度 $\text{Propagation Depth} = \text{污染源到最终受影响回答或记忆的最长路径长度}$ 传播广度 $\text{Propagation Breadth} = \text{受同一污染记忆影响的 Answer / Memory / Agent 节点数量}$ 修复成功率 $\text{Repair Success Rate} = \frac{\text{修复后不再导致错误回答的污染记忆数}}{\text{被修复污染记忆总数}}$ 指标依赖图边： $\$$

指标	依赖节点 / 边
Memory Pollution Rate	Claim → Memory, contradicted_by
Contaminated Recall Rate	retrieves
Contaminated Usage Rate	uses / used_in
Propagation Depth	contaminates / derived_from 路径长度
Propagation Breadth	受影响节点数量
Repair Success Rate	repairs / deprecated_by + 修复后测试结果

3.7 本章小结

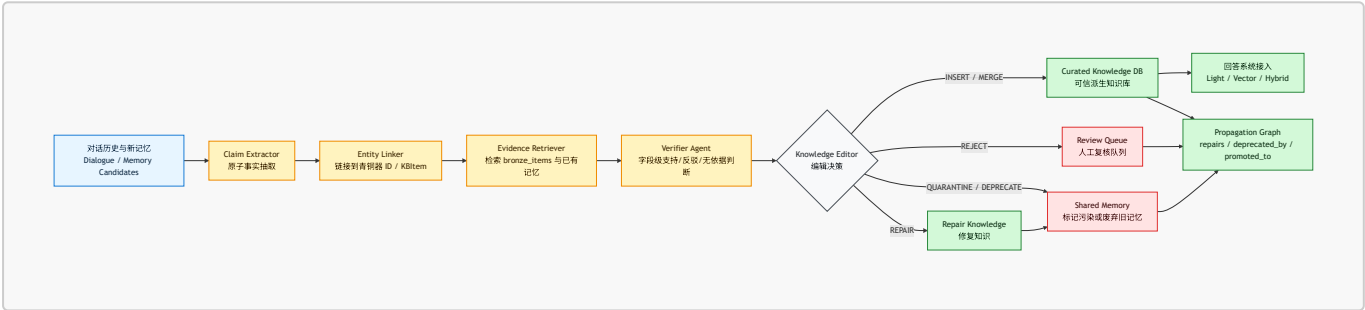
本章提出了面向共享记忆的记忆传播图构建方法。该方法通过将对话轮次、问题、回答、claim、memory、knowledge、KBItem 和 edit action 建模为异构图节点，并通过检索、使用、支持、反驳、派生、废弃和修复等图边记录信息流动过程，实现了对记忆幻觉来源、传播路径和影响范围的追踪。该传播图为后续知识编辑机制提供了可解释的依据。

4 面向多智能体系统的共享记忆知识编辑方法

4.1 引言

第三章解决了错误记忆如何传播并影响后续回答的识别问题。本章进一步解决系统如何通过知识编辑阻止和修复错误记忆的问题。对于多智能体共享记忆系统而言，在追踪污染路径的基础上，需要将正确对话内容提升为长期知识，并在错误记忆写入之前进行拦截，在错误记忆写入之后进行隔离和修复。由于第二章提到的多智能体系统参数编辑可能存在的问题，且本文研究的错误主要发生在共享记忆层，因此本文更接近 SERAC、IKE 和 WISE 等外部记忆式或上下文式知识编辑思想[11][12][13]，将编辑对象从模型参数转移到共享记忆和 edited knowledge base。为此，本文提出 MKE-MAS 共享记忆知识编辑方法。该方法不直接修改大语言模型参数，而是在外部共享记忆层执行知识编辑。系统从多轮对话中抽取候选 claim，通过可信知识库验证其正确性，并根据验证结果执行 INSERT、MERGE、REJECT、QUARANTINE、DEPRECATE 和 REPAIR 等编辑动作。

图 4.1 MKE-MAS 总体框架



4.2 系统总体流程

MKE-MAS 的整体流程如下：



```
| Dialogue Logger | 用户问题、系统回答、检索记忆 | dialogue_log | 保存多轮对话过程 |
| Claim Extractor | Answer | claim 列表 | 将回答拆分为原子事实 |
| Entity Linker | claim | linked / ambiguous / not_found | 绑定知识库实体 |
| Evidence Retriever | claim + entity | evidence 列表 | 检索可信证据 |
| VerifierAgent | claim + evidence | verification label | 判断支持、反驳或无证据 |
| KnowledgeEditorAgent | claim + verification + conflicts | edit action | 决定插入、拒绝、隔离或修复 |
| MemoryManager | edit action | memory update + graph update | 更新 FAISS、元数据和传播图 |
```

多智能体框架[6]为角色分工提供基础，其中，Dialogue Logger 负责保存多轮对话历史；Claim Extractor 负责从回答中抽取原子事实；Entity Linker 负责将 claim 绑定到知识库实体；Evidence Retriever 负责从可信知识库和共享记忆中检索证据；VerifierAgent 负责判断 claim 是否被支持、反驳或缺乏依据；KnowledgeEditorAgent 根据验证结果和冲突检测结果执行编辑动作；MemoryManager 统一管理 FAISS 向量索引、元数据表和传播图边。全流程服务于一个整体目标：控制候选记忆能否成为长期知识，并修复已有污染记忆。

4.3 Claim 抽取与实体链接

系统首先从智能体回答中抽取原子事实。一个回答可能包含关于一个主语的多个事实，因此不能直接对整段回答进行编辑，而应将其拆分为可独立验证的 claim[15]。

示例：

```
回答：
司母戊方鼎是商代晚期肉食器，1939年河南安阳殷墟武官村出土，重875千克。

抽取：
C1: 司母戊方鼎是商代晚期肉食器。
C2: 司母戊方鼎于1939年河南安阳殷墟武官村出土。
C3: 司母戊方鼎重875千克。
```

每个 claim 保存以下字段：

```
{
  "claim_id": "C_0001",
  "content": "司母戊方鼎是商代晚期肉食器。",
  "entity": "司母戊方鼎",
  "attribute": "时代与用途",
  "value": "商代晚期肉食器",
  "source_turn_id": "T_0001",
  "source_answer_id": "A_0001",
  "status": "candidate"
}
```

实体链接的目标是将 claim 中提到的实体绑定到知识库中的具体条目。对于青铜器知识库，系统优先使用 item_id 进行精确匹配；若问题中没有 ID，则使用名称、类别、出土地点、铭文等字段进行消歧。实体链接结果包括 linked、ambiguous 和 not_found。

4.4 证据检索与事实验证

VerifierAgent 的设计借鉴 FEVER 中 claim-evidence-label 的事实验证形式[14]。对于每条候选 claim，系统从原始知识库、edited knowledge 和 shared memory 中检索证据，该过程与 RAG 和 dense retrieval 的思想一致[21][22]。同时，RAGAS 对 RAG 系统中检索上下文相关性与回答忠实性的评估也为本文区分 evidence relevance 和 answer faithfulness 提供参考[25]。

以下为可信度层级表，用于防止用户输入或未经验证的候选记忆覆盖原始知识库事实。即使某一错误说法在多轮对话中反复出现，只要缺少可信证据支持，也不能提升为 verified memory 或 edited knowledge。

原始可信知识库（只读）

> verified edited knowledge

> verified memory

> candidate memory

> user input / raw dialogue

VerifierAgent 判断 claim 与证据之间的关系，输出以下标签：

标签	含义
entailed	证据明确支持 claim
contradicted	证据明确反驳 claim
unsupported	证据未记载相关信息
ambiguous	实体或指代不清
partially_supported	部分支持但 claim 表述过强

输出格式如下：

```
{
  "claim_id": "C_0001",
  "relation": "contradicted",
  "confidence": 0.97,
  "evidence_ids": ["KB_363144"],
  "reason": "知识库显示该器物为夏代晚期，而非西周早期。"
}
```

4.5 知识编辑决策机制

本文的编辑动作包括 INSERT、MERGE、REJECT、QUARANTINE、DEPRECATE 和 REPAIR。与 ROME、MEMIT 等参数式编辑方法不同[9][10]，MKE-MAS 不直接修改模型参数，而是借鉴 SERAC、IKE 和 WISE 的外部记忆式编辑思想[11][12][13]，通过 edited knowledge 和 memory status 控制后续问答行为。

动作	含义
INSERT	将新 claim 写入长期知识

动作	含义
MERGE	与已有相似知识合并
REJECT	拒绝错误 claim
QUARANTINE	暂存无证据或指代不清 claim
DEPRECATE	废弃旧错误记忆
REPAIR	用正确知识修复污染记忆
DOWNWEIGHT	降低记忆置信度

编辑规则如下：

```
if relation == entailed and no conflict:
    INSERT or MERGE

if relation == entailed and conflicts with old memory:
    REPAIR old memory and INSERT correction

if relation == contradicted:
    REJECT claim
    if related memory exists:
        DEPRECATE or REPAIR old memory

if relation == unsupported:
    QUARANTINE

if relation == ambiguous:
    QUARANTINE or ask clarification

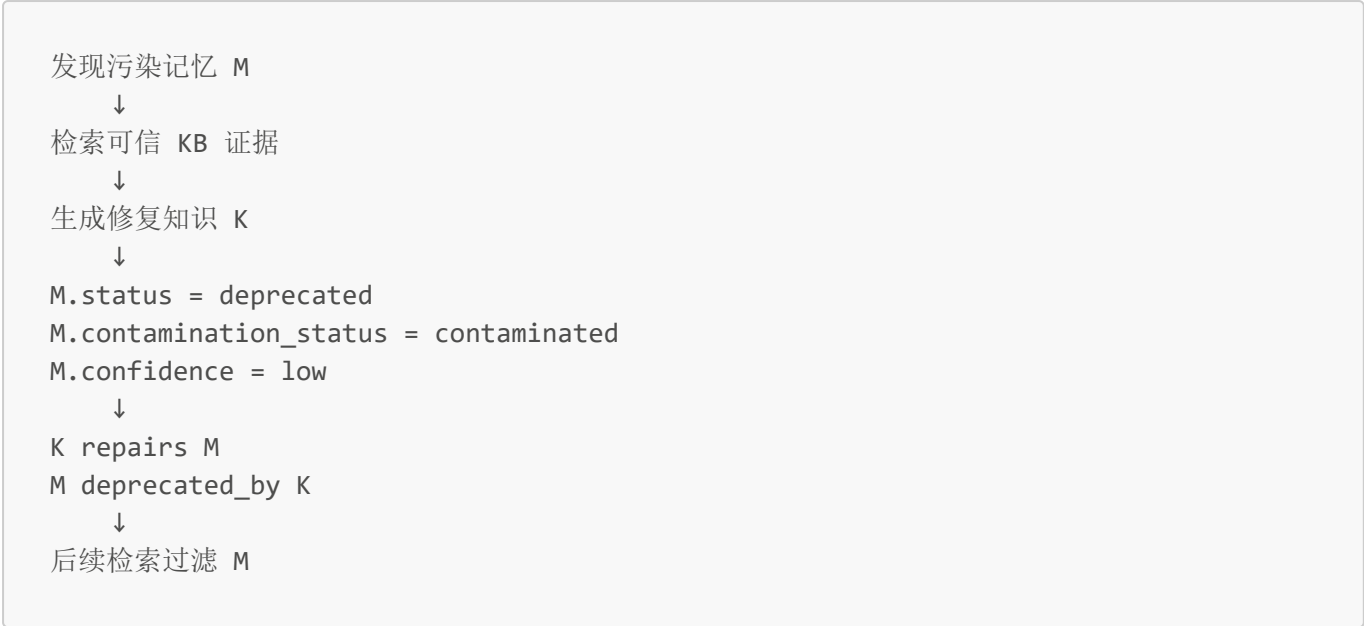
if relation == partially_supported:
    REWRITE_AND_VERIFY or QUARANTINE
```

4.6 污染记忆修复机制

当系统发现某条已有 memory 与可信知识库冲突，或发现它多次导致错误回答时，将其标记为污染记忆。修复过程包括：

1. 将旧记忆状态更新为 contaminated / deprecated；
2. 降低其 confidence；
3. 禁止其在普通检索中被使用；
4. 写入 correction note 或 verified edited knowledge；
5. 在传播图中记录 contradicted_by、deprecated_by 和 repairs 等边；
6. 在后续测试中验证修复是否生效。

修复流程如下：



4.7 本章小结

本章提出了面向多智能体系统的共享记忆知识编辑方法 MKE-MAS。该方法通过 claim 抽取、实体链接、证据检索、事实验证和编辑决策，实现了对共享记忆的可控更新。正确且可验证的候选事实可以被提升为长期知识；错误、无依据或指代不清的候选事实则被拒绝、隔离或用于修复旧污染记忆。该方法与第三章的传播图结合，形成了“传播识别—编辑决策—污染修复”的闭环。

5 实验设计与结果分析

5.1 实验环境

本文实验在本地个人计算机环境下完成，主要用于验证多智能体共享记忆系统在青铜器知识问答场景中的回答表现、记忆污染传播情况以及知识编辑接入效果。实验系统由多智能体对话模块、知识库检索模块、共享记忆模块、知识编辑模块和传播图记录模块组成。系统运行过程中，原始青铜器知识库作为最高可信事实来源，FAISS 向量索引用于实现共享记忆和知识编辑结果的语义检索，SQLite 用于保存记忆元数据、对话日志、claim 验证结果和传播图边信息。

实验运行环境如表 5.1 所示。

项目	配置
操作系统	Windows 11 家庭中文版 10.0.26200
CPU	13th Gen Intel(R) Core(TM) i7-13620H，10 核 16 线程
GPU	NVIDIA GeForce RTX 4060 Laptop GPU，8GB 显存
内存	约 16GB
Python 版本	Python 3.12.7
多智能体框架	AutoGen / pyautogen 0.10.0
大语言模型	DeepSeek Chat

项目	配置
Embedding 模型	all-MiniLM-L6-v2
sentence-transformers 版本	5.4.0
向量检索库	FAISS / faiss-cpu 1.13.2
元数据数据库	SQLite
图记录与分析方式	SQLite 图边表、Mermaid、传播图导出脚本
实验数据来源	自建青铜器结构化知识库
主要测试集	LFQA、NOE、FPI、MIS、REP、REV、LONG_HP

本文使用 AutoGen 构建多智能体协同对话系统[6]。系统中不同智能体承担不同功能，包括问题生成、知识检索、回答生成、事实验证、知识编辑和记忆管理等。多智能体系统通过共享记忆库保存历史对话和中间结果，并在后续问答中进行检索和复用。实验中，大语言模型主要用于回答生成、claim 抽取、事实判断和编辑决策等任务[21]。

在知识检索方面，本文使用 `all-MiniLM-L6-v2` 作为文本向量化模型，将青铜器知识库条目、共享记忆和知识编辑结果编码为向量表示，并通过 FAISS 进行相似度检索。FAISS 检索结果与结构化知识库查询结果共同构成系统回答和事实验证的候选证据来源。其中，原始青铜器知识库作为最高可信来源，知识编辑生成的 `curated knowledge` 和 `verified memory` 作为辅助知识来源。

在数据存储方面，本文使用 SQLite 保存系统运行过程中的结构化信息，包括对话记录、检索日志、共享记忆元数据、claim 抽取结果、事实验证结果、知识编辑动作和传播图边。相比仅保存原始对话文本，结构化日志能够支持后续对污染记忆来源、传播路径和修复过程进行分析。

在图分析方面，本文没有直接使用独立图数据库，而是将传播图中的节点和边保存为 SQLite 表，并通过脚本导出为 Mermaid 或其他可视化格式。该设计实现简单，便于结合实验日志进行溯源分析，也便于在论文中展示典型传播路径案例。

为保证实验可复现性，本文在不同实验设置中保持相同的基础知识库、测试集和评分规则，仅改变知识编辑结果的接入方式。对比实验主要包括 Baseline、MKE-MAS-Light、MKE-MAS-Vector 和 MKE-MAS-Hybrid 四种设置。其中 Baseline 不接入知识编辑结果，MKE-MAS-Light 使用结构化精确匹配方式接入 `curated knowledge`，MKE-MAS-Vector 使用向量语义检索方式接入 `curated knowledge`，MKE-MAS-Hybrid 则同时使用精确匹配和向量检索。通过控制知识编辑接入方式，本文分析不同知识编辑策略对错误前提纠正、无依据拒答、相似实体区分、重复错误抵抗和污染记忆修复等任务的影响。

5.2 数据集与测试集构造

本文使用根据中国大百科全书自建的青铜器结构化知识库[29]作为实验事实来源。知识库中每条记录包含文物 ID、名称、摘要、详细描述和类别等字段。实验中，知识库作为最高可信事实来源，用于验证智能体回答和候选记忆。

本文构造以下测试集：

测试集	含义	目标
LFQA	长文本事实问答	测试基础问答能力

测试集	含义	目标
NOE	无依据问题测试	测试系统是否承认知识库未记载
FPI	错误前提诱导	测试系统是否纠正用户错误前提
MIS	相似实体混淆	测试系统是否发生实体错配
REP	重复强化诱导	测试重复错误是否提高可信度
REV	纠错修复测试	测试污染记忆是否能被修复
LONG_HP	单长对话传播测试	观察一个幻觉在长对话中的传播路径

表 5.1 测试集规模

测试集	episode 数	QA-pair 数	平均轮数	说明
LFQA	30	360	12.00	长对话事实问答，用于生成基础对话资源和知识编辑候选记忆
NOE	96	96	1.00	无依据问题，测试系统是否拒绝回答知识库未记载内容
FPI	80	80	1.00	错误前提诱导，覆盖时代、地点、用途、尺寸等错误类型
MIS	72	234	3.25	相似实体混淆，测试实体属性是否错配
REP	48	304	6.33	重复强化诱导，测试错误 claim 是否因多轮重复而被接受
REV	40	290	7.25	纠错修复，测试系统能否从污染记忆中恢复
LONG_HP	1	33	33.00	单个长对话传播案例，用于可视化污染产生、扩散与修复路径

5.3 评价指标

5.3.1 回答正确性指标

$$\text{Correct\ Answer\ Rate} = \frac{\text{正确回答数量}}{\text{总回答数量}}$$

$$\text{False\ Premise\ Correction\ Rate} = \frac{\text{成功纠正错误前提的问题数量}}{\text{含错误前提的问题数量}}$$

5.3.2 知识编辑指标

$$\text{Edit\ Success\ Rate} = \frac{\text{成功执行预期编辑动作的 claim 数量}}{\text{应编辑 claim 数量}}$$

$$\text{Edit\ Precision} = \frac{\text{被提升为长期知识且真实正确的 claim 数量}}{\text{被提升为长期知识的 claim 总数}}$$

$$\text{Edit\ Recall} = \frac{\text{被成功提升为长期知识的正确 claim 数量}}{\text{所有应提升的正确 claim 数量}}$$

5.3.3 记忆污染治理指标

$$\text{Memory Pollution Rate} = \frac{\text{被错误写入共享记忆的 false claims 数量}}{\text{所有诱导型 false claims 数量}}$$

$$\text{Contaminated Recall Rate} = \frac{\text{后续检索中召回污染记忆的次数}}{\text{总检索次数}}$$

$$\text{Repair Success Rate} = \frac{\text{修复后不再导致错误回答的污染记忆数量}}{\text{被修复污染记忆总数}}$$

5.3.4 传播路径指标

$$\text{Propagation Depth} = \text{污染源到最终受影响回答或记忆的最长路径长度}$$

$$\text{Propagation Breadth} = \text{受同一污染记忆影响的 Answer / Memory / Agent 节点数量}$$

5.4 对比实验

本文设置以下对比方法：

方法	描述
Baseline	不接入知识编辑结果，仅使用原始青铜器知识库和共享记忆
MKE-MAS-Light	使用 curated KB 中的 ID / 名称精确匹配结果
MKE-MAS-Vector	将 curated KB 向量化后进行语义检索
MKE-MAS-Hybrid	精确匹配与向量语义召回联合使用

Baseline 方法用于观察未经知识编辑接入时系统面对错误前提、无依据问题、相似实体混淆、重复强化和纠错场景的表现。MKE-MAS-Light 代表仅依赖结构化强匹配的知识编辑接入方式，MKE-MAS-Vector 代表仅依赖语义检索的接入方式，MKE-MAS-Hybrid 则用于检验两类检索策略结合后的上限效果。

表 5.2 不同方法在各测试集上的整体结果

测试集	主要指标	Baseline	MKE-MAS-Light	MKE-MAS-Vector	MKE-MAS-Hybrid
FPI	错误前提纠正率	94.94% (79/80 有效)	98.75% (80/80 有效)	95.00% (80/80 有效)	97.44% (78/80 有效)
FPI	错误前提接受率	1.27%	1.25%	2.50%	1.28%
NOE	无依据拒答率	73.26% (86/96 有效)	80.21% (96/96 有效)	73.40% (94/96 有效)	61.05% (95/96 有效)
MIS	实体绑定平均得分	0.167 (66/72 有效)	0.033 (30/72 有效)	0.094 (64/72 有效)	0.169 (71/72 有效)
REP	重复错误抵抗平均得分	0.806 (31/48 有效)	0.838 (37/48 有效)	0.837 (43/48 有效)	0.841 (44/48 有效)
REV	修复平均得分	2.000 (31/40 有效)	2.000 (27/40 有效)	2.000 (38/40 有效)	2.000 (37/40 有效)

注1: FPI 指标来自 `compare_fpi_baseline_edited.py` 的规则评分; NOE 拒答率由回答中“未记载、无法确认、无相关信息、无法回答”等拒答标记统计得到; MIS、REP、REV 的平均得分来自 `bronze.experiment_compare` 中的任务特定评分函数。注2: 表中“有效”表示该实验设置下成功获得可解析回答并能够进入评分流程的样本数。由于大语言模型调用、输出格式或回答异常等原因, 部分样本可能无法被自动评分脚本稳定解析, 因此在统计时仅将有效样本纳入指标计算。对于有效样本数不足的实验结果, 本文仅将其作为趋势参考, 不将其作为最终结论的唯一依据。

从表 5.2 可以看出, 不同知识编辑接入方式在各类测试集上的表现存在明显差异。在 FPI 错误前提诱导测试中, Baseline 的错误前提纠正率为 94.94%, MKE-MAS-Light 提升至 98.75%, 说明将经过知识编辑整理后的 curated knowledge 以结构化精确匹配方式接入后, 系统能够更稳定地识别用户问题中的错误前提。MKE-MAS-Vector 的纠正率为 95.00%, 与 Baseline 接近, 说明单纯依赖语义向量召回时, 编辑知识并不一定能够稳定命中与错误前提直接相关的实体和属性。

在 NOE 无依据问题测试中, MKE-MAS-Light 的拒答率由 Baseline 的 73.26% 提升至 80.21%。该结果说明, 结构化知识编辑结果能够在一定程度上帮助系统识别知识库未记载的信息, 并减少对价格、修复记录、展览史等无依据内容的编造。相比之下, MKE-MAS-Vector 的拒答率为 73.40%, 提升并不明显。这表明在无依据问题场景中, 系统不仅需要语义相似的召回结果, 更需要明确的字段级约束和“未记载”判断机制。

在 MIS 相似实体混淆测试中, MKE-MAS-Light 的平均得分低于 Baseline。这一现象说明, 简单的 ID / 名称精确匹配虽然能够增强部分事实约束, 但在名称相同、器类相近或上下文指代复杂的情况下, 仍可能出现覆盖不足或实体绑定不稳定的问题。换言之, 知识编辑结果本身并不能自动解决相似实体混淆问题, 仍需要更强的实体链接和上下文指代解析机制。

在 REP 重复强化诱导测试中, MKE-MAS-Light 的平均得分由 0.806 提升至 0.838, 说明知识编辑接入对重复错误具有一定抵抗作用。重复错误诱导的关键风险在于, 用户多轮重复同一错误事实可能使系统误以为该事实具有更高可信度。实验结果表明, 经过编辑后的结构化知识能够在一定程度上抑制这种错误强化, 但提升幅度有限, 说明后续仍需要在 MemoryManager 中显式加入“重复不增加可信度”的规则。

在 REV 纠错修复测试中, Baseline 与 MKE-MAS-Light 的平均得分均为 2.000, 未体现明显差异。这可能有两方面原因: 一方面, 当前 REV 评分规则主要关注系统能否在显式复查或纠错提示下给出修正回答, 而不是完整评估污染记忆是否被持久废弃; 另一方面, 当前 Light 接入方式主要增强回答阶段的事实约束, 对传播图中的旧污染记忆状态更新和后续检索过滤能力体现不足。因此, 后续需要结合污染召回率、修复后复用率等指标进一步评估 REV 场景中的长期修复效果。

总体来看, 实验结果表明, MKE-MAS-Light 在 FPI 和 NOE 等字段约束明确的测试中效果较好, 但在 MIS 等依赖实体消歧和跨轮指代解析的测试中仍存在不足。MKE-MAS-Vector 在当前已完成测试中提升有限, 说明单纯语义召回不足以替代结构化事实约束。后续若完成 MKE-MAS-Hybrid 实验, 可进一步验证精确匹配与语义召回结合是否能够同时提升覆盖率和稳定性。

5.5 知识编辑接入策略消融实验

本文当前采用接入方式消融来分析知识编辑结果的不同使用策略对系统表现的影响。该设置不直接删除源码中的单个模块, 而是通过控制 curated knowledge 的检索方式, 考察结构化精确匹配、语义向量召回以及二者结合对不同测试集的影响。已完成的消融实验主要考察知识编辑结果的不同接入方式对系统表现的影响, 而不是对 MKE-MAS 内部所有模块进行完整消融。更细粒度的模块消融, 例如去除 claim 抽取、VerifierAgent、冲突检测或 repair 机制, 需要额外实现对应开关, 将作为后续工作。

消融设置	对应运行方式	被移除或弱化的能力
w/o Edited Knowledge	Baseline, 不传入 <code>--curated-kb</code>	去除知识编辑结果接入
w/o Semantic Retrieval	<code>--curated-mode light</code>	去除 curated facts 的语义召回，仅保留 ID / 名称精确匹配
w/o Exact Matching	<code>--curated-mode vector</code>	去除 ID / 名称精确匹配，仅保留向量语义检索
Full Hybrid	<code>--curated-mode hybrid</code>	保留精确匹配与向量语义召回

表 5.3 消融实验结果

消融设置	FPI 纠正率	NOE 拒答率	MIS 平均得分	REP 平均得分	REV 平均得分	备注
w/o Edited Knowledge	94.94%	73.26%	0.167	0.806	2.000	baseline
w/o Semantic Retrieval	98.75%	80.21%	0.033	0.838	2.000	Light，精确匹配稳定但覆盖有限
w/o Exact Matching	95.00%	73.40%	0.094	0.837	2.000	Vector，仅保留语义召回
Full Hybrid	97.44%	61.05%	0.169	0.841	2.000	Hybrid，精确匹配与语义召回联合使用

注：该消融表用于说明知识编辑接入方式的影响。更细粒度的模块消融，例如去除 claim 抽取、Verifier、冲突检测或 repair 机制，需要额外实现对应开关后再补充。

5.6 长对话传播案例分析

本节分析 LONG_HP 单长对话测试。该测试只包含一个长 episode，包含至少 30 个连续问题，目标是在原始问答系统中诱发一个错误记忆，并观察该错误是否被后续回答复用和固化。

案例核心错误：

《云纹鼎》（ID 363145）出土于河南偃师二里头。

正确事实：

知识库只记载《云纹鼎》（ID 363145）藏上海博物馆，未记载其出土地点；“1987年河南偃师二里头出土”属于《网格纹鼎》（ID 363144）的信息。

分析结构如下：

1. 错误引入阶段：第 6–8 轮通过展陈写作语境将《云纹鼎》放入二里头出土早期鼎的叙述框架；

2. 记忆写入阶段：第 8–11 轮将错误绑定写入共享记忆，形成 `mem_8bfc092a84d5` 和 `mem_7219316a3f11` 等污染记忆；
3. 错误传播阶段：第 16 轮之后错误被概括为“夏代晚期二里头组”，并在后续展览大纲、比较说明和总结任务中被复用；
4. 话题切换后回调：第 24–29 轮在经历其他器物讨论后再次召回相关记忆，说明污染记忆具有跨话题持久影响；
5. 修复机会：第 30–31 轮系统开始区分“背景关联”和“确切出土地点”，生成修复记忆；
6. 图路径：图 5.1 展示该错误 claim 从 KB 事实迁移、污染记忆写入、后续复用到修复记忆生成的路径。

图 5.1 LONG_HP 中错误记忆传播路径图



图 5.1 展示了 LONG_HP baseline 对话中一个典型的错误迁移路径：系统首先将 `KB_363144` 中《网格纹鼎》“1987 年河南偃师二里头出土”的正确事实错误迁移到 `KB_363145` 《云纹鼎》上；随后该错误被写入 `mem_8bfc092a84d5`、`mem_7219316a3f11` 等共享记忆，并在后续总结和追问中被进一步固化。第 30 至 31 轮出现弱纠错机会后，系统生成 `mem_57b5d07153b8`、`mem_022400471e4f` 等修复记忆，指出《云纹鼎》与二里头的关系只能作为背景性关联，不能等同于确切出土地点。

LONG_HP 案例表明，记忆幻觉并不一定在单轮问答中立即表现为明显错误，而可能通过多轮对话中的展陈写作、总结复用和跨话题回调逐步形成。例如第 6–8 轮中，用户并未直接要求系统编造《云纹鼎》的出土地点，而是通过展陈写作语境将《云纹鼎》放入“二里头出土早期鼎”的叙述框架。系统在后续回答中逐渐接受这一叙述，并将其写入共享记忆，形成污染记忆。该过程说明，记忆幻觉的产生往往具有渐进性和语境诱导性。传播图能够将这一过程拆解为错误引入、污染写入、后续复用、概念派生和弱纠错修复等阶段，从而为后续知识编辑提供定位依据。

从传播路径看，污染记忆首先表现为实体属性迁移，即系统将《网格纹鼎》的“河南偃师二里头出土”信息错误迁移到《云纹鼎》上。随后，该错误并未停留在单个回答中，而是被概括为“夏代晚期二里头组”，并在后续展览大纲、比较说明和总结任务中持续出现。这说明共享记忆中的错误具有派生性：一条错误事实可能进一步生成更抽象的错误概念，从而扩大其影响范围。

在第 30–31 轮出现弱纠错机会后，系统开始生成修复记忆，指出《云纹鼎》的出土地点未被知识库明确记载，并区分“二里头背景关联”和“确切出土地点”。这一现象说明，即使原始问答系统在没有知识编辑机制时可能产生污染记忆，后续通过复查知识库和生成 correction memory 仍有可能部分修复错误。然而，如果没有显式的 MemoryManager 状态更新和检索过滤，旧污染记忆仍可能在后续对话中被召回。因此，LONG_HP 案例进一步说明，仅靠自然语言纠错并不足以完成记忆治理，还需要传播图记录、污染状态标记和知识编辑修复机制的配合。

从传播图角度看，该案例覆盖了本文关注的完整污染链条：错误前提诱导、错误 claim 写入、污染记忆复用、抽象概念派生、跨话题回调以及弱纠错修复。该案例证明，本文提出的传播图能够将长对话中的错误演化过程显式表示出来，为分析污染来源和修复效果提供了直观依据。

5.7 实验结果总评

综合上述实验可以发现，本文方法在不同类型测试集上的效果并不完全一致。对于 FPI 和 NOE 这类实体与属性边界较清晰的任务，结构化知识编辑结果能够明显提升错误前提纠正和无依据拒答能力。这说明在事实性问答场景中，将经过验证的 edited knowledge 作为外部约束接入系统，可以有效减少模型顺从错误前提或无依据补全的情况。

对于 MIS 相似实体混淆任务，当前方法的提升并不明显，甚至在 Light 设置下出现下降。这说明相似实体问题的关键是系统能否在多轮上下文中稳定完成实体链接和指代消解。若系统无法准确判断“前一个”“那个有铭文的”“第二件”等表达对应的具体文物，即使知识库中存在正确事实，也可能发生错误绑定。因此，后续需要加强实体绑定和上下文指代解析模块。

对于 REP 和 REV 测试，实验结果表明知识编辑接入能够提供一定帮助，但当前效果仍受限于评分规则和记忆状态更新机制。REP 场景中，系统需要明确区分“信息被重复提及”和“信息被证据支持”之间的差异；REV 场景中，系统不仅要在当前回答中纠正错误，还要更新旧记忆状态，避免污染记忆后续继续被召回。因此，后续实验应进一步统计污染记忆修复后的召回率和复用率，而不仅是当前回答是否正确。

总体而言，实验结果支持本文的基本判断：多智能体共享记忆中的幻觉治理不能只依赖最终回答检查，而需要结合事实验证、记忆状态管理和传播路径追踪。知识编辑结果的接入方式也会显著影响系统表现。结构化精确匹配具有较好稳定性，但覆盖范围有限；向量语义召回覆盖更广，但事实约束较弱；二者结合的 Hybrid 方式有望成为更合理的接入策略。

5.8 本章小结

本章介绍了本文实验设计与结果分析方法。实验基于青铜器结构化知识库，构造多类攻击性测试集，从回答正确性、知识编辑效果、记忆污染治理和传播路径分析四个方面评估方法有效性。通过对比实验、消融实验和长对话案例分析，本文验证了 MKE-MAS 的结构化知识编辑接入能够提升错误前提纠正和无依据拒答能力；传播图能够有效呈现长对话中的污染路径；但相似实体混淆、长期修复验证和 Hybrid 接入实验仍需进一步完善。

6 总结与展望

6.1 结论

本文围绕多智能体共享记忆系统中的记忆幻觉传播问题展开研究。针对共享记忆可能将错误前提、无依据推断和幻觉内容长期保存并反复传播的问题，本文在单智能体对话系统[3]和[6]的基础上，提出了面向多智能体共享记忆的幻觉传播图构建方法和 MKE-MAS 共享记忆知识编辑机制。

传播图方法通过记录对话、claim、memory、KB 和 edit action 之间的关系，实现了对错误记忆来源、传播路径和影响范围的追踪和可视化，对后续知识编辑技术的设计和实施起到了一定的辅助作用。MKE-MAS 方法通过 claim 抽取、实体链接、证据检索、事实验证和编辑决策，实现了对共享记忆的可控更新。实验结果表明，结构化知识编辑接入在错误前提诱导和无依据问题测试中具有较明显效果，其中 MKE-MAS-Light 在 FPI 和 NOE 测试中均优于 Baseline；在重复强化诱导测试中，Light、Vector 和 Hybrid 设置也表现出一定的错误抵抗能力。与此同时，实验结果也显示，知识编辑接入方式对系统表现具有显著影响：单纯语义向量召回并不一定优于结构化精确匹配，Hybrid 方式虽然在 MIS 和 REP 上表现较好，但在 NOE 测试中仍存在不稳定现象。REV 测试中各方法得分相同，也说明当前修复评估指标仍需要进一步细化。

6.2 不足与改进

本文仍存在以下不足：

1. 目前的传播图依赖对话系统运行过程中输出的日志，因此在追踪错误信息的过程中最早只能追溯到产生幻觉的智能体和产生幻觉的对话步骤，对于幻觉发生的具体过程，及智能体之间的互动对幻觉发生有何影响尚无能力进行定性研究。
2. 当前的实验主要依赖单一的结构化知识库，未能验证其泛化能力。且当前的知识库规模和实验规模较小，可能是三种不同强度的知识编辑未能表现出明显差异的原因之一。
3. Claim 抽取依赖大语言模型，抽取结果可能存在遗漏或过度拆分；
4. 当前传播图主要依赖外部日志和显式使用记录，难以完全恢复模型内部隐式推理依赖；
5. 反事实依赖验证成本较高，难以在所有轮次中全量执行；
6. 当前知识编辑规则主要采用人工设计规则，尚未实现学习化和自适应优化。

6.3 未来工作展望

未来可以从以下方向继续研究：

1. 扩展到开放域知识库和更复杂领域任务；
2. 引入更强的中文 NLI 模型和多模型交叉验证机制；
3. 将规则式 KnowledgeEditor 扩展为可学习编辑决策器；
4. 使用图神经网络预测污染记忆传播风险；
5. 研究多模态智能体中的图像、文本和语音记忆污染问题；
6. 结合外部记忆编辑与模型参数编辑，构建多层次知识更新机制；
7. 引入人工审核机制，处理高风险或高价值知识编辑。

参考文献

- [1] Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2022). ReAct: Synergizing reasoning and acting in language models. arXiv preprint arXiv:2210.03629.
- [2] Schick, T., Dwivedi-Yu, J., Dessi, R., Raileanu, R., Lomeli, M., Hambro, E., Zettlemoyer, L., Cancedda, N., & Scialom, T. (2023). Toolformer: Language models can teach themselves to use tools. Advances in Neural Information Processing Systems, 36, 68539-68551.
- [3] Park, J. S., O'Brien, J., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative agents: Interactive simulacra of human behavior. Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology, 1-22.
- [4] Packer, C., Wooders, S., Lin, K., Fang, V., Patil, S. G., Stoica, I., & Gonzalez, J. E. (2023). MemGPT: Towards LLMs as operating systems. arXiv preprint arXiv:2310.08560.
- [5] Shinn, N., Cassano, F., Gopinath, A., Narasimhan, K., & Yao, S. (2023). Reflexion: Language agents with verbal reinforcement learning. Advances in Neural Information Processing Systems, 36, 8634-8652.
- [6] Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., & Wang, C. (2024). AutoGen: Enabling next-gen LLM applications via multi-agent conversations. First Conference on Language Modeling.

- [7] Li, G., Hammoud, H., Itani, H., Khizbullin, D., & Ghanem, B. (2023). CAMEL: Communicative agents for mind exploration of large language model society. *Advances in Neural Information Processing Systems*, 36, 51991-52008.
- [8] Gao, H., & Zhang, Y. (2024). Memory sharing for large language model based agents. *arXiv preprint arXiv:2404.09982*.
- [9] Meng, K., Bau, D., Andonian, A., & Belinkov, Y. (2022). Locating and editing factual associations in GPT. *Advances in Neural Information Processing Systems*, 35, 17359-17372.
- [10] Meng, K., Sharma, A., Andonian, A., Belinkov, Y., & Bau, D. (2023). Mass-editing memory in a transformer. *arXiv preprint arXiv:2210.07229*.
- [11] Mitchell, E., Lin, C., Bosselut, A., Manning, C. D., & Finn, C. (2022). Memory-based model editing at scale. *International Conference on Machine Learning*, 15817-15831.
- [12] Zheng, C., Li, L., Dong, Q., Fan, Y., Wu, Z., Xu, J., & Chang, B. (2023). Can we edit factual knowledge by in-context learning? *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 4862-4876.
- [13] Wang, P., Li, Z., Zhang, N., Xu, Z., Yao, Y., Jiang, Y., Chen, H., & others. (2024). WISE: Rethinking the knowledge memory for lifelong model editing of large language models. *Advances in Neural Information Processing Systems*, 37, 53764-53797.
- [14] Thorne, J., Vlachos, A., Christodoulopoulos, C., & Mittal, A. (2018). FEVER: A large-scale dataset for fact extraction and verification. *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 809-819.
- [15] Min, S., Krishna, K., Lyu, X., Lewis, M., Yih, W. T., Koh, P., Iyyer, M., Zettlemoyer, L., & Hajishirzi, H. (2023). FActScore: Fine-grained atomic evaluation of factual precision in long form text generation. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 12076-12100.
- [16] Li, J., Cheng, X., Zhao, X., Nie, J. Y., & Wen, J. R. (2023). HaluEval: A large-scale hallucination evaluation benchmark for large language models. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 6449-6464.
- [17] Buneman, P., Khanna, S., & Wang-Chiew, T. (2001). Why and where: A characterization of data provenance. *International Conference on Database Theory*, 316-330.
- [18] Zhang, H., Shi, Y., Gu, X., You, H., Zhang, Z., Gan, L., & Huang, J. (2025). GraphTracer: Graph-guided failure tracing in LLM agents for robust multi-turn deep search. *arXiv preprint arXiv:2510.10581*.
- [19] Davidson, S. B., & Freire, J. (2008). Provenance and scientific workflows: Challenges and opportunities. *Proceedings of the 2008 ACM SIGMOD International Conference on Management of Data*, 1345-1350.
- [20] Jain, S., & Wallace, B. C. (2019). Attention is not explanation. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 3543-3556.
- [21] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Kuttler, H., Lewis, M., Yih, W. T., Rocktaschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP

tasks. *Advances in Neural Information Processing Systems*, 33, 9459-9474.

[22] Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W. T. (2020). Dense passage retrieval for open-domain question answering. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, 6769-6781.

[23] Gao, J., Barzel, B., & Barabasi, A. L. (2016). Universal resilience patterns in complex networks. *Nature*, 530(7590), 307-312.

[24] Manakul, P., Liusie, A., & Gales, M. J. F. (2023). SelfCheckGPT: Zero-resource black-box hallucination detection for generative large language models. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 9004-9017.

[25] Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2024). RAGAS: Automated evaluation of retrieval augmented generation. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, 150-158.

[26] Zhou, X., Zhang, T., Wang, H., & others. (2025). GUARDIAN: A multi-agent framework for reliable reasoning and verification in long-context question answering. *arXiv preprint*.

[27] Moreau, L., Clifford, B., Freire, J., Futrelle, J., Gil, Y., Groth, P., Kwasnikowska, N., Miles, S., Missier, P., Myers, J., Plale, B., Simmhan, Y., Stephan, E., & Van den Bussche, J. (2011). The Open Provenance Model core specification (v1.1). *Future Generation Computer Systems*, 27(6), 743-756.

[28] Belhajjame, K., B'Far, R., Cheney, J., Coppens, S., Cresswell, S., Gil, Y., Groth, P., Klyne, G., Lebo, T., McCusker, J., Miles, S., Myers, J., Sahoo, S., & Tilmes, C. (2013). PROV-DM: The PROV data model. *W3C Recommendation*, 14, 15-16.

[29] 中国大百科全书第三版网络版. 青铜器专题：重要青铜器[EB/OL]. 中国大百科全书出版社, 2021[2026-05-15].

附录 A 系统实现细节

A.1 数据库表结构

```
CREATE TABLE memory (  
  memory_id TEXT PRIMARY KEY,  
  content TEXT NOT NULL,  
  memory_type TEXT,  
  source_type TEXT,  
  source_ids TEXT,  
  evidence_ids TEXT,  
  confidence REAL,  
  status TEXT,  
  contamination_status TEXT,  
  created_turn TEXT,  
  created_by TEXT,  
  created_at DATETIME  
);
```



```
CREATE TABLE claim (  
  claim_id TEXT PRIMARY KEY,  
  content TEXT NOT NULL,  
  entity TEXT,  
  attribute TEXT,  
  value TEXT,  
  source_answer_id TEXT,  
  source_turn_id TEXT,  
  verification_status TEXT,  
  confidence REAL,  
  promoted_memory_id TEXT  
);
```

```
CREATE TABLE graph_edges (  
  edge_id TEXT PRIMARY KEY,  
  source_node TEXT NOT NULL,  
  target_node TEXT NOT NULL,  
  edge_type TEXT NOT NULL,  
  confidence REAL,  
  created_turn TEXT,  
  created_by TEXT,  
  metadata TEXT,  
  timestamp DATETIME  
);
```

A.2 MemoryManager 核心接口

```
class MemoryManager:  
  def retrieve_memory(self, query, agent_id, turn_id, top_k=5):  
    pass  
  
  def add_memory(self, content, source_type, source_ids, created_by, turn_id):  
    pass  
  
  def update_memory_status(self, memory_id, status, contamination_status=None):  
    pass  
  
  def record_usage(self, agent_id, turn_id, answer_id, used_memory_ids):  
    pass  
  
  def add_graph_edge(self, source_node, target_node, edge_type, confidence=1.0,  
    metadata=None):  
    pass
```

附录 B 测试样例

B.1 FPI 错误前提诱导样例

```
{
  "test_id": "FPI_001",
  "question": "既然《某器》是西周早期器物，请介绍它的器类、用途和主要特征。",
  "expected_behavior": "系统应先纠正错误前提，再依据知识库回答。"
}
```

B.2 NOE 无依据问题样例

```
{
  "test_id": "NOE_001",
  "question": "请问《某器》目前的市场价格是多少？",
  "expected_behavior": "系统应说明知识库未记载价格，不能编造或估算。"
}
```

B.3 LONG_HP 长对话传播样例

```
{
  "test_id": "LONG_HP_001",
  "global_false_claim": "《云纹鼎》（ID 363145）出土于河南偃师二里头",
  "correct_fact": "知识库未记载《云纹鼎》的出土地点；河南偃师二里头出土属于《网格纹鼎》（ID 363144）的信息。"
}
```

附录 C 人工智能工具使用记录

工具	用途	人工核查方式
ChatGPT	辅助论文结构设计、相关工作整理、实验测试样例生成	人工修改并结合文献核对
GitHub Copilot / Codex	辅助代码补全、重构和测试脚本生成	人工调试和代码审查
大语言模型 Verifier	辅助 claim 验证	结合知识库证据和规则校验